



MODELO COMPUTACIONAL PARA INFERÊNCIA DE DINÂMICAS SOCIAIS EM CETÁCEOS A PARTIR DE DADOS VIDEOGRÁFICOS AÉREOS

Reinan Lopes Argolo¹ – rlargolo.cic@uesc.br

Lucas Santiago Carmo dos Santos² – lscsantos.cic@uesc.br

Susana Marrero Iglesias³ – smiglesias@uesc.br

Paulo Eduardo Ambrósio⁴ – peambrosio@uesc.br

Bianca Machado Righi⁵ – biancamrighi@gmail.com

¹ Universidade Estadual de Santa Cruz – Ilhéus – BA

² Universidade Estadual de Santa Cruz – Ilhéus – BA

³ Universidade Estadual de Santa Cruz – Ilhéus – BA

⁴ Universidade Estadual de Santa Cruz – Ilhéus – BA

⁵ Universidade Estadual de Santa Cruz – Ilhéus – BA

Resumo. *O estudo do comportamento social de cetáceos é uma ferramenta fundamental para a biologia da conservação, dificultado pela natureza laboriosa da extração de dados a partir de observações. O advento de Veículos Aéreos Não Tripulados (VANTs) intensificou este desafio ao gerar volumes massivos de dados visuais, tornando a análise manual impraticável. Este trabalho apresenta um modelo computacional para a extração automática de dinâmicas espaço-temporais de baleias jubarte (*Megaptera novaeangliae*) a partir de filmagens aéreas. O algoritmo proposto articula a rede neural convolucional YOLOv8 (You Only Look Once) para a detecção de indivíduos com o algoritmo de rastreamento DeepSORT para a reconstrução de trajetórias temporais. O submodelo de detecção foi validado empiricamente, alcançando uma Precisão Média de 98,82% (mAP@0.5) e 72,33% (mAP@0.5:0.95), atestando sua alta fidelidade na localização dos agentes do sistema. A integração desses componentes resulta em um modelo robusto que transforma dados visuais não estruturados em séries temporais de estados (posições e distâncias), viabilizando a modelagem quantitativa de interações comportamentais em larga escala e contribuindo para estratégias de preservação ambiental.*

Palavras-Chave: *Visão Computacional, Deep Learn, YOLO, DeepSORT, VANTs.*

1. INTRODUÇÃO

A modelagem de sistemas ecológicos é um componente essencial para a formulação de estratégias de conservação ambiental, especialmente em ecossistemas marinhos sujeitos a intensas alterações (Campos, 2014). Dentro deste domínio, a modelagem quantitativa do comportamento social de cetáceos apresenta-se como um desafio notável, pois a extração de parâmetros dinâmicos a partir de observações diretas é metodologicamente exigente e de baixa escalabilidade. Tradicionalmente, a coleta de dados dependia de técnicas como observação embarcada ou censos aéreos, que não apenas introduzem um potencial viés observacional, mas também levantam questões éticas significativas devido à perturbação gerada aos animais (Castrillon; Bengtson Nash, 2020; Simões; Macedo; Engel, 2005).

O advento de plataformas de sensoriamento remoto, como os Veículos Aéreos Não Tripulados (VANTs), inaugurou uma nova era na aquisição de dados etológicos, permitindo o

registro de interações sociais com alta resolução espaço-temporal e mínimo impacto invasivo (Alencar et al., 2020; Koike, 2015). Contudo, a nova ferramenta de coleta gerou uma lentidão no processamento dada a proliferação de vastos repositórios de vídeos, cuja complexidade visual exacerbada por fatores como turbidez da água e reflexos especulares torna a análise manual um processo temporalmente proibitivo e não escalável (Hodgson; Peel; Kelly, 2017). Este cenário evidencia a necessidade premente de paradigmas computacionais capazes de automatizar a conversão de dados visuais brutos em representações numéricas tratáveis.

Para endereçar esta lacuna, este artigo detalha o desenvolvimento e a validação de um modelo computacional híbrido para a inferência de estados dinâmicos de interação em grupos de baleias jubarte. O modelo proposto articula um subcomponente de percepção visual, baseado na arquitetura de rede neural convolucional YOLO (You Only Look Once), com um módulo de associação temporal, o algoritmo DeepSORT. A função primária deste sistema é transformar fluxos de vídeo não estruturados em séries temporais de vetores de estado, contendo as coordenadas e as distâncias interindividuais. Ao automatizar a extração destes parâmetros fundamentais, o modelo estabelece uma base empírica para a subsequente modelagem de fenômenos comportamentais, viabilizando a análise quantitativa em uma escala anteriormente inatingível (Weinstein, 2018).

2. REVISÃO BIBLIOGRÁFICA

A modelagem computacional tem emergido como um paradigma central na etologia quantitativa, oferecendo um arcabouço formal para traduzir observações de sistemas biológicos complexos em modelos matemáticos e simuláveis (Potts; Mokross; Lewis, 2014). Diferentemente de um algoritmo isolado, que executa uma tarefa específica, um modelo computacional busca representar a dinâmica de um sistema, capturando as relações entre seus componentes e permitindo a inferência de seus estados ao longo do tempo. No contexto do monitoramento da vida selvagem com dados visuais, a modelagem se manifesta através de pipelines que integram submodelos para percepção, associação e análise, transformando dados brutos em parâmetros comportamentais significativos (Muktiarni; Isma, 2023).

2.1 Redes Neurais aplicadas à detecção de baleias

A primeira etapa na modelagem de um sistema de múltiplos agentes a partir de dados visuais consiste em determinar o estado espacial de cada indivíduo em um instante de tempo. Esta tarefa é formalizada como um problema de detecção de objetos. As Redes Neurais Convolucionais (CNNs) representam o estado da arte para a construção de tais modelos de percepção espacial. Trabalhos anteriores na área de monitoramento de cetáceos têm empregado CNNs com sucesso para tarefas de contagem e localização (Boulent et al., 2023; Guirado et al., 2019). No entanto, uma lacuna persistente na literatura é a transição da mera detecção para a modelagem explícita de interações espaciais, como a proximidade. O trabalho de Alsaïdi et al. (2024), por exemplo, aplica um modelo de detecção a um problema similar, mas não avança para a modelagem das relações interindividuais.

Existem duas principais classes de modelos de detecção. Modelos de dois estágios, como o Faster R-CNN, primeiro geram propostas de regiões e depois as classificam, oferecendo alta precisão de localização (Guirado et al., 2019). Em contraste, modelos de estágio único, como a família YOLO (You Only Look Once), tratam a detecção como um problema de regressão unificado (SSD) (Diwan; Anirudh; Tembhurne, 2022). Para a modelagem de sistemas dinâmicos a partir de vídeo, os modelos de estágio único são frequentemente preferíveis devido à sua eficiência computacional, que permite o processamento de sequências temporais longas

em tempo viável. O YOLO, portanto, foi selecionado não apenas como um algoritmo, mas como a base para o nosso submodelo de inferência de estado espacial instantâneo.

2.2 Rastreamento dos indivíduos

A inferência do estado espacial em quadros isolados é insuficiente para a detecção de comportamento, que são inerentemente um processo temporal. É necessário, portanto, um método de rastreamento que estabeleça a correspondência identitária dos agentes ao longo do tempo, reconstruindo suas trajetórias. A abordagem dominante para esta tarefa é o paradigma de *tracking-by-detection*, que busca associar as saídas do modelo de percepção espacial entre quadros consecutivos. O algoritmo DeepSORT representa um modelo híbrido robusto para esta tarefa, pois articula um modelo de movimento, o Filtro de Kalman, com um modelo de aparência baseado em deep learning.

O Filtro de Kalman funciona como um modelo preditivo que estima a posição futura de um indivíduo com base em sua trajetória passada, conferindo ao sistema uma capacidade de lidar com oclusões de curta duração. O modelo de aparência, por sua vez, extrai uma assinatura visual (embedding) de cada indivíduo, permitindo a desambiguação em cenários de alta densidade ou cruzamento de trajetórias. A interação entre YOLO e DeepSORT tem sido validada em outras áreas da ecologia computacional, como na contagem e rastreamento de peixes (Khiem et al., 2025), demonstrando a eficácia desta combinação para a construção de um modelo completo de dinâmica espaço-temporal. A integração destes dois submodelos, portanto, constitui o núcleo do nosso framework de modelagem, transformando detecções pontuais em trajetórias contínuas que representam a evolução do sistema ao longo do tempo.

3. METODOLOGIA

A metodologia adotada para a inferência de dinâmicas sociais em cetáceos se materializa em um algoritmo computacional, concebido como um modelo integrado para a transformação de dados. O fluxo de trabalho de treinamento da rede, esquematizado na Figura 1, é arquitetado para processar sistematicamente observações visuais brutas e convertê-las em séries temporais de parâmetros comportamentais quantificáveis. A construção deste modelo inicia-se com o estabelecimento de uma base empírica, que compreende a aquisição de dados e a curadoria do dataset. Através disso, é desenvolvido o submodelo de percepção espacial para a identificação de indivíduos em cada instante de tempo. As subseções subsequentes procederão à descrição detalhada dos componentes que constituem estas fases fundamentais do modelo.

3.1 Aquisição dos dados e construção do dataset

A validade de qualquer modelo computacional depende fundamentalmente da qualidade e representatividade dos dados utilizados para seu treinamento e validação. Análises preliminares, conduzidas com datasets públicos (Detect, 2023), revelaram um *domain gap* significativo, onde as condições ambientais e os padrões comportamentais divergiam do contexto de estudo, resultando em um desempenho de detecção subótimo com um $mAP@0.5$ de 67%. Tal constatação tornou necessária a construção de um dataset customizado que servisse como a base empírica para o modelo proposto.

Os dados primários consistem em filmagens aéreas de baleias jubarte, coletadas no Banco dos Abrolhos (16°40'S – 19°30'S; 37°25'W – 39°45'W) com o uso de um Veículo Aéreo Não Tripulado (VANT). A aquisição seguiu um protocolo de captura padronizado para garantir a consistência dos dados, com o VANT mantido a uma altitude fixa de 20 metros. Para permitir a calibração espacial do modelo e a conversão de pixels para unidades métricas, um objeto de referência com 1 metro de comprimento foi registrado sob as mesmas condições de voo. Os vídeos, com durações entre 0:21 e 2:48 minutos e taxas de quadros variáveis (24-60 fps), foram

então submetidos a um pré-processamento para a extração de fotogramas. Visando mitigar a redundância temporal e otimizar a diversidade do conjunto de treinamento, aplicou-se uma estratégia de amostragem para selecionar apenas os quadros-chave, uma prática que também contribui para a regularização do modelo, prevenindo o sobreajuste (overfitting) (Muhammad et al., 2022).

3.2 Anotação do Dataset

A transformação dos fotogramas extraídos em um dataset de treinamento supervisionado requer um processo de anotação semântica, no qual as informações visuais de interesse são convertidas em um formato estruturado. Para esta tarefa, foi empregada a plataforma CVAT (Computer Vision Annotation Tool), selecionada após uma avaliação comparativa de sua robustez e estabilidade em um ambiente de desenvolvimento containerizado, o Docker. A utilização do CVAT garantiu a integridade e a consistência do processo de rotulagem.

Um protocolo de anotação foi definido para mapear cada instância de baleia a uma representação geométrica. Este protocolo consistiu na demarcação de *bounding boxes* que englobassem a menor área retangular contendo a totalidade da massa corporal visível do indivíduo. A aplicação consistente desta diretriz em todo o conjunto de dados foi fundamental para minimizar a ambiguidade e garantir a alta qualidade do ground truth para o treinamento do modelo de percepção espacial.

O processo culminou na geração de um dataset final composto por 402 imagens, contendo um total de 867 instâncias de baleias anotadas. Para assegurar uma validação experimentalmente sólida do modelo, este conjunto foi particionado de forma estratificada em três subconjuntos mutuamente exclusivos: Treinamento (70%), Validação (20%) e Teste (10%). As anotações foram então exportadas e normalizadas para o formato exigido pela arquitetura YOLO, finalizando a construção da base de dados que serve como substrato empírico para as etapas subsequentes de modelagem.

3.3 Treinamento do modelo e validação do modelo

O núcleo do pipeline é constituído por um modelo de percepção espacial, responsável pela detecção e localização dos indivíduos em cada instante de tempo. Para a implementação deste submodelo, foi selecionada a arquitetura de rede neural convolucional YOLOv8 (You Only Look Once). A escolha desta arquitetura foi motivada por seu balanço computacionalmente eficiente entre acurácia de detecção e velocidade de inferência, um requisito essencial tanto para a análise de grandes volumes de vídeos quanto para a viabilidade de futuras implementações em sistemas embarcados, como VANTs autônomos. O modelo foi desenvolvido sobre o framework PyTorch.

O processo de ajuste dos parâmetros do modelo (weights) foi conduzido através de uma estratégia de *transfer learning* com fine-tuning. Partiu-se de uma rede pré-treinada no dataset COCO, capitalizando o conhecimento de características visuais genéricas para acelerar a convergência e aprimorar a generalização no nosso domínio de dados específico (Pan; Yang, 2010). O treinamento foi estruturado como um processo iterativo de otimização, conforme ilustrado no fluxograma da Figura 1. Em cada iteração, o modelo foi treinado com o conjunto de dados de treino, utilizando imagens redimensionadas para 736x736 pixels e submetidas a um processo de *data augmentation* dinâmico, que incluiu transformações geométricas e fotométricas para aumentar a robustez do modelo.

A otimização dos parâmetros foi realizada pelo algoritmo Stochastic Gradient Descent (SGD) com *momentum*, um método para a minimização de *loss-function* em espaços de alta dimensionalidade. Conforme o laço de realimentação do fluxograma, o desempenho do modelo era continuamente monitorado no conjunto de validação, utilizando a métrica de Precisão Média (mAP). Com base nesta avaliação, hiperparâmetros como o tamanho do batch size e a

taxa de aprendizado foram ajustados entre as iterações, em um esforço para encontrar a configuração que melhor se adaptasse ao contexto. Este processo de calibração, conduzido por múltiplas épocas, culminou na seleção do modelo que apresentou o maior desempenho de generalização, servindo como o submodelo de percepção espacial final para o pipeline.




Figura 1 – Fluxo de treinamento do modelo de inferência

3.3 Calibração do modelo por fine-tuning

Modelos computacionais de percepção visual, especialmente os baseados em aprendizado profundo, são altamente sensíveis às especificidades do domínio de aplicação (Tuia et al., 2022). A variabilidade intrínseca do ambiente marinho — como flutuações na turbidez da água, iluminação e oclusões dinâmicas causadas pelo comportamento dos próprios animais (Boulent et al., 2023) — exige mais do que um treinamento único. Para assegurar a robustez do submodelo de percepção espacial, foi implementado um protocolo de *fine-tuning* iterativo, guiado pela análise de erros, visando a melhoria do modelo para os cenários de maior complexidade e relevância etológica.

A análise do desempenho do modelo de base revelou déficits sistemáticos em situações de alta importância para a modelagem de interações, como a oclusão parcial de filhotes pelo corpo da mãe ou o cruzamento de trajetórias. Tais cenários frequentemente resultavam em falhas de detecção ou na fusão de múltiplas instâncias em uma única caixa delimitadora. Para mitigar estes erros, a estratégia de fine-tuning foi estruturada como um ciclo de realimentação: o modelo era aplicado a dados de validação empírica, os modos de falha eram identificados e, subsequentemente, o conjunto de dados de treinamento era enriquecido com exemplos que representavam explicitamente essas condições adversas. Ao expor iterativamente o modelo aos seus próprios pontos de falha, forçou-se o aprendizado de características mais discriminativas.

Este processo de otimização guiada por erro não se limitou à recomposição do dataset. A cada iteração, os hiperparâmetros do treinamento, como a taxa de aprendizado e as políticas de aumento de dados, também eram reavaliados e ajustados para refinar o processo de convergência. O ciclo foi repetido até que o modelo atingisse um nível de desempenho satisfatório em todos os cenários de interesse. Este processo resultou em um submodelo de percepção espacial final com capacidade de generalização e precisão substancialmente aprimoradas, apto para a integração com o módulo de identificação temporal.

3.4 Reconstrução de trajetória com DeepSORT

A saída do submodelo de percepção espacial consiste em um conjunto de estados instantâneos e descorrelacionados. Para o estudo do comportamento, é necessário conectar esses estados ao longo do tempo, reconstruindo as trajetórias individuais de cada ser no sistema.

Esta tarefa de associação temporal é realizada por uma rede de rastreamento, para o qual foi adotada a abordagem híbrida do algoritmo DeepSORT (Wojke; Bewley; Paulus, 2017). Este modelo integra um componente preditivo de movimento com um componente de aparência visual para estabelecer a correspondência identitária entre quadros consecutivos.

O componente preditivo é implementado através de um Filtro de Kalman, um estimador estocástico que identifica a cinemática de cada indivíduo. O filtro prediz o estado futuro (posição e velocidade) de uma trajetória, permitindo a manutenção da identidade mesmo na ausência de detecções por curtos períodos, como em oclusões momentâneas. Em paralelo, o componente de aparência utiliza uma rede neural convolucional (Howard et al., 2017) para extrair um vetor de características de alta dimensionalidade de cada detecção. Esta assinatura visual serve como um descritor de identidade, permitindo que o modelo realize a desambiguação em cenários complexos, como o cruzamento de trajetórias, com base na similaridade visual.

A análise empírica revelou que, embora robusto, este modelo de associação temporal apresenta limitações sob condições de oclusão prolongada ou quando um agente sai e reentra no campo de visão. Nestes casos, o modelo pode incorrer em erros de fragmentação de trajetória, onde uma nova identidade é indevidamente atribuída. A frequência destes artefatos nos dados observados indicou a necessidade de incorporar uma etapa de pós-processamento. Portanto, o modelo completo de rastreamento adotado neste trabalho consiste na aplicação do DeepSORT seguida por um módulo de refinamento heurístico, projetado para fundir trajetórias fragmentadas pertencentes ao mesmo indivíduo, garantindo assim a integridade temporal dos dados para a análise final.

3.5 Extração de Parâmetros e Inferência de Papéis Comportamentais

A culminação do pipeline de modelagem é a conversão das trajetórias espaço-temporais em um conjunto de parâmetros quantitativos e descritores comportamentais de alto nível. Este processo de extração de características (feature extraction) é executado iterativamente sobre cada quadro do vídeo, analisando os pares de indivíduos identificados para derivar as métricas de interação.

Um dos componentes deste modelo é a inferência automática de papéis comportamentais provisórios (mãe, filhote, escorte). Dado que as baleias jubarte não apresentam dimorfismo sexual visualmente aparente (Medrano et al., 1994), a classificação é realizada através de um algoritmo baseado em critérios morfométricos e proximicos. Dinamicamente, o modelo atribui o papel de 'filhote' ao indivíduo que apresenta a menor área de caixa delimitadora e mantém uma proximidade espacial persistente com um indivíduo significativamente maior, que por sua vez é classificado como 'mãe'. Outros indivíduos associados ao grupo são categorizados como 'escortes'. Esta classificação de papéis, embora inferencial, adiciona uma camada semântica aos dados, permitindo análises contextualizadas.

Para cada par de indivíduos classificados, são computados dois parâmetros espaciais fundamentais: a Distância Euclidiana entre os centroides, convertida para metros via calibração, e o vetor de Posição Relativa (dx , dy). A combinação destes parâmetros com os papéis inferidos permite a análise de dinâmicas relacionais específicas, como a distância mãe-filhote versus a distância mãe-escorte. O conjunto completo de dados — incluindo identificadores, coordenadas, papéis e parâmetros calculados — é organizado e exportado em formato tabular, além de ser utilizado para gerar visualizações gráficas com a biblioteca Matplotlib. Este produto constitui uma base de dados estruturada, pronta para o subsequente estudo estatístico e de análise de padrões comportamentais.

4. RESULTADOS E VALIDAÇÃO

4.1 Performance do modelo de detecção

A validação do modelo computacional inicia-se pela avaliação de seu subcomponente de percepção espacial, responsável pela detecção e localização dos indivíduos. A performance do detector YOLOv8 final, resultante do processo de calibração iterativa, foi aferida de forma rigorosa no conjunto de teste. Este procedimento garante uma estimativa não enviesada da capacidade de generalização do modelo em dados não vistos. A Tabela I apresenta os resultados consolidados, demonstrando a alta fidelidade do modelo.

O submodelo alcançou uma Precisão Média de 98.2% sob o critério de Interseção sobre União (IoU) de 0.5 ($mAP@0.5$), indicando uma capacidade quase perfeita de identificar corretamente as instâncias de baleias. Na métrica mais restritiva, $mAP@0.5:0.95$, que avalia a precisão da localização em múltiplos limiares de IoU, o modelo atingiu 72.0%. Este resultado, combinado com valores de Precisão e recall próximos da unidade, valida o submodelo como um extrator de estado espacial de alta confiabilidade, capaz de identificar a presença dos agentes do sistema com um número mínimo de falsos positivos ou falsos negativos.

Tabela 1- Performance do Modelo

YOLOv8n			
<i>Precisão</i>	<i>Recall</i>	<i>mAP@0.5</i>	<i>mAP@0.5:0.95</i>
~1.00	~0.995	0.982	~0.72

A robustez do processo de treinamento que levou a este desempenho é corroborada pela análise das curvas de aprendizado (Figura 2). A convergência suave das funções de perda no conjunto de validação e a estabilização das métricas de acurácia em um patamar elevado indicam que o modelo atingiu um ponto ótimo de generalização, sem incorrer em sobreajuste (overfitting). A estabilidade demonstrada durante o treinamento confere credibilidade adicional à performance final aferida no conjunto de teste, solidificando a validade do submodelo de percepção como o alicerce do pipeline de análise.




Figura 2 – Gráficos das métricas de treinamento do modelo

4.2 Performance do tracker

Uma vez validado o submodelo de percepção espacial, a avaliação focou-se no desempenho do submodelo de dinâmica temporal, responsável pela reconstrução das trajetórias individuais. A performance do algoritmo DeepSORT foi quantificada utilizando o conjunto de métricas HOTA e CLEAR MOT, cujos resultados para o conjunto de teste são sumarizados na Tabela 2. A análise destas métricas permite validar a capacidade do modelo em manter a coerência identitária dos agentes ao longo do tempo, um requisito essencial para a modelagem de interações.

Tabela 2 - Performance do Modulo de Identificação dos indivíduos

DeepSORT		
<i>Métrica</i>	<i>Descrição</i>	<i>%</i>
IDF1	F1-Score	0,95
IDP	Precisão	0,953
IDR	Recall	0,947
MOTA	Acurácia de Tracking	0,959
Ids	Trocas de Identidade	4
FM	Fragmentação da Trilha de segmento	16
MOTP	Precisão de Localização (IoU)	0,226

O desempenho na manutenção da identidade mostrou-se excepcionalmente robusto. O modelo alcançou um F1-Score de Identificação (IDF1) de 95.0%, indicando um alto grau de acerto na associação correta das detecções às suas respectivas trajetórias. Este resultado é corroborado pelo número irrisório de trocas de identidade e pela capacidade do modelo de rastrear a totalidade das trajetórias de referência (ground truth) de forma majoritária. A combinação deste rastreamento consistente com a alta performance do detector subjacente culmina em uma Acurácia Geral de Rastreamento (MOTA) de 95.9%, validando o pipeline como uma ferramenta de alta fidelidade para a modelagem da presença e identidade individual.

Em contrapartida, a análise das métricas revelou um trade-off explícito entre a consistência da identificação e a precisão da localização. O baixo valor da métrica de Precisão de Rastreamento (MOTP = 0.226), que mede a sobreposição média (IoU) entre as caixas delimitadoras preditas e as de referência, indica uma delimitação espacial subótima. Este resultado sugere que, embora o modelo identifique corretamente quais agentes estão presentes e mantenha suas identidades, ele exibe imprecisão ao definir seus contornos exatos. Para a modelagem de interações baseada em centroides, como a proposta neste trabalho, o impacto desta imprecisão é mitigado; contudo, ela representa uma limitação para futuras modelagens que dependam de parâmetros morfométricos precisos, apontando para a necessidade de explorar modelos de segmentação de instância.

4.3 Análise quantitativa do Comportamento

A validação final do pipeline integra uma análise qualitativa do seu comportamento operacional. A Figura 3 apresenta fotogramas exemplificativos da saída do sistema, onde se observa a aplicação simultânea da detecção, rastreamento e extração de métricas de distância. Estas imagens corroboram visualmente as conclusões da análise quantitativa: a alta fidelidade na manutenção da identidade dos indivíduos (alto IDF1) e a limitação na precisão das caixas delimitadoras (baixo MOTP), particularmente em condições de baixa visibilidade. A funcionalidade central do modelo, contudo, permanece robusta.




Figura 3 – Gráficos das métricas de treinamento do modelo

A culminação do processo de modelagem é a extração de um conjunto de parâmetros quantitativos que descrevem a dinâmica de interação social. A Figura 4 apresenta três visualizações fundamentais geradas a partir das séries temporais de vetores de estado extraídas de um vídeo de teste. O gráfico de distâncias temporais (Figura 4) provê uma visão detalhada da evolução da proximidade entre cada par de agentes, permitindo a modelagem de eventos de afiliação e dissociação. A matriz de distâncias médias (Figura 5) oferece uma sumarização estatística da estrutura social do grupo, onde a proximidade acentuada entre os indivíduos 0 e 2 ($2.02\text{m} \pm 0.68$) sugere uma forte ligação, como a de um par mãe-filhote. Finalmente, o gráfico de posição relativa polar (Figura 6) permite a modelagem de padrões de movimento coordenado, ao mapear a trajetória de um agente em um sistema de referência centrado em outro. Em conjunto, estas saídas constituem a base de dados gerada pelo modelo, pronta para a subsequente análise estatística e etológica.




Figura 4 – Gráfico de distâncias intra-indivíduos




Figura 5 - Gráfico de distâncias média entre as baleias




Figura 6 - Gráfico de posicionamento relativos dos indivíduos

5. DISCUSSÃO E CONCLUSÃO

Este trabalho apresentou o desenvolvimento e a validação de um modelo computacional para a inferência de dinâmicas sociais em cetáceos, demonstrando a sinergia entre submodelos de percepção espacial e associação temporal. O sucesso do pipeline é atribuído fundamentalmente ao processo de calibração do detector YOLOv8 através de ajuste fino iterativo, que especializou o modelo para as adversidades do ambiente marinho. Esta alta fidelidade na percepção foi um pré-requisito para que o submodelo de rastreamento DeepSORT pudesse reconstruir trajetórias com elevada consistência de identidade, conforme validado pelas métricas de MOTA (95.9%) e IDF1 (95.0%). O modelo proposto, portanto, supera a barreira da análise manual, oferecendo um método objetivo, escalável e reprodutível para a extração de parâmetros proximicos a partir de dados observacionais.

A análise dos resultados revelou um trade-off inerente à arquitetura do submodelo de percepção: a otimização para velocidade e consistência de identificação resultou em uma precisão de localização subótima (MOTP de 0.226). Embora esta limitação seja mitigada para a modelagem de interações baseada em centroides, ela evidencia uma direção clara para aprimoramentos futuros através da incorporação de modelos de segmentação de instância. As expansões futuras do modelo não se limitam à melhoria de seus componentes. O verdadeiro potencial reside na utilização de suas saídas — as séries temporais de vetores de estado — como base para a modelagem relacional e preditiva do comportamento. Seria possível, por exemplo, desenvolver modelos baseados em agentes ou cadeias de Markov para prever transições entre estados comportamentais (e.g., de 'viagem' para 'interação social') com base nos parâmetros extraídos.

Em conclusão, este artigo propõe um modelo computacional para o monitoramento comportamental de baleias jubarte, que integra de forma robusta técnicas de visão computacional para a extração de parâmetros de interação. Ao viabilizar a análise quantitativa de vastos conjuntos de dados de VANTs, este trabalho não apenas oferece uma ferramenta de suporte à pesquisa etológica, mas também contribui com uma base metodológica para a expansão de estratégias de conservação marinha, permitindo um monitoramento mais amplo, rápido e objetivo das populações e de suas dinâmicas sociais.

Agradecimentos

Este estudo foi financiado pelo Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq).

REFERÊNCIAS

- ALENCAR, Ana Emília Barbosa et al. Uso de aeronaves não tripuladas (DRONES) para pesquisa e monitoramento de peixe-boi-marinho e seu habitat. , 2020.
- ALSAIDI, Mostapha et al. Frontiers Localization and tracking of beluga whales in aerial video using deep learning. 2024.
- BOULENT, Justine et al. Scaling whale monitoring using deep learning: A human-in-the-loop solution for analyzing aerial datasets. *Frontiers in Marine Science*, v. 10, 10 mar. 2023.
- CAMPOS, Edmo J. D. O papel do oceano nas mudanças climáticas globais. *REVISTA USP*, n. 103, 2014.
- CASTRILLON, Juliana; BENGTON NASH, Susan. Evaluating cetacean body condition; a review of traditional approaches and new developments. *Ecology and Evolution*, v. 10, n. 12, p. 6144–6162, 13 maio 2020.
- DETECT, Whale. Aerial Right Whale Detection Dataset. , 2023. Disponível em: <<https://universe.roboflow.com/whale-detect/aerial-right-whale-detection>>. Acesso em: 1 jul. 2025
- DIWAN, Tausif; ANIRUDH, G.; TEMBHURNE, Jitendra V. Object detection using YOLO: challenges, architectural successors, datasets and applications. *Multimedia Tools and Applications*, v. 82, n. 6, p. 9243–9275, 8 ago. 2022.
- GUIRADO, Emilio et al. Whale counting in satellite and aerial images with deep learning. *Scientific Reports*, v. 9, n. 1, p. 14259, 3 out. 2019.
- HODGSON, Amanda; PEEL, David; KELLY, Natalie. Unmanned aerial vehicles for surveying marine fauna: assessing detection probability. *Ecological Applications*, v. 27, n. 4, p. 1253–1267, 2017.
- HOWARD, Andrew G. et al. MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications. *arXiv*, , 17 abr. 2017. Disponível em: <<http://arxiv.org/abs/1704.04861>>. Acesso em: 24 jul. 2025
- KHIEM, Nguyen Minh et al. A novel approach combining YOLO and DeepSORT for detecting and counting live fish in natural environments through video. 2025.
- KOIKE, Christine Del Vecchio. O tamanho corporal de baleias-jubarte (*Megaptera novaeangliae*) estimado por fotogrametria e a sua influência na distribuição espaço-temporal nas áreas reprodutivas. [S.l.]: UESC, 2015.
- MEDRANO, L. et al. Sex identification of humpback whales, *Megaptera novaeangliae*, on the wintering grounds of the Mexican Pacific Ocean. *Canadian Journal of Zoology*, v. 72, n. 10, p. 1771–1774, 1 out. 1994.
- MUHAMMAD, Bilyamin et al. Keyframe Extraction for Low-Motion Video Summarization Using K-Means Clustering. *ELEKTRIKA- Journal of Electrical Engineering*, v. 21, n. 2, p. 1–6, 1 set. 2022.
- MUKTIARNI, M.; ISMA, Widiaty. Bibliometric Analysis of The Integration of Digital Tools in Marine Conservation Education. *Indonesian Journal of Educational Research and Technology*, p. 305–314, 2023.
- POTTS, Jonathan R.; MOKROSS, Karl; LEWIS, Mark A. A unifying framework for quantifying the nature of animal interactions. *Journal of The Royal Society Interface*, 6 jul. 2014.
- SIMÕES, Diana Gonçalves; MACEDO, Regina Helena Ferraz; ENGEL, Márcia H. Turismo de observação de cetáceos como ferramenta no estudo do comportamento de baleias Jubarte (*Megaptera novaeangliae*). 2005.
- SRIVASTAVA, Nitish et al. Dropout: A Simple Way to Prevent Neural Networks from Overfitting. 2014.
- TUIA, Devis et al. Perspectives in machine learning for wildlife conservation. *Nature Communications*, v. 13, n. 1, 9 fev. 2022.
- WEINSTEIN, Ben G. A computer vision for animal ecology. *Journal of Animal Ecology*, v. 87, n. 3, p. 533–545, 2018.
- WOJKE, Nicolai; BEWLEY, Alex; PAULUS, Dietrich. Simple Online and Realtime Tracking with a Deep Association Metric. *arXiv*, , 21 mar. 2017. Disponível em: <<http://arxiv.org/abs/1703.07402>>. Acesso em: 24 jul. 2025

APÊNDICE A

COMPUTATIONAL MODEL FOR INFERENCE OF SOCIAL DYNAMICS IN CETACEANS FROM AERIAL VIDEOGRAPHIC DATA

Abstract. The study of cetacean social behavior is a fundamental tool for conservation biology, hindered by the laborious nature of data extraction from observations. The advent of Unmanned Aerial Vehicles (UAVs) has intensified this challenge by generating massive volumes of visual

data, making manual analysis impractical. This work presents a computational model for the automatic extraction of spatio-temporal dynamics of humpback whales (*Megaptera novaeangliae*) from aerial footage. The proposed algorithm integrates the YOLOv8 (You Only Look Once) convolutional neural network for individual detection with the DeepSORT tracking algorithm for temporal trajectory reconstruction. The detection submodel was empirically validated, achieving a Mean Average Precision of 98.82% (mAP@0.5) and 72.33% (mAP@0.5:0.95), demonstrating its high reliability in locating the system's agents. The integration of these components results in a robust model that transforms unstructured visual data into time series of states (positions and distances), enabling the quantitative modeling of behavioral interactions at scale and contributing to environmental preservation strategies.

Keywords: *Computer Vision, Deep Learn, YOLO, DeepSORT, VANTs.*